Agent KHU

MCP 기반 AI 캠퍼스 정보 플랫폼

정윤서 · 경희대학교 컴퓨터공학부

2025년 9월 ~ 2025년 12월

프로젝트 배경

🔴 문제 정의

경희대학교 학사정보가 **8개 이상의 플랫폼**에 분산

- 학교 공식 홈페이지 (학사 공지)
- 학과별 웹사이트 (학과 공지)
- SNS 채널 (학생회 공지)
- 개별 시스템 (수강신청, 도서관 등)

⚠️ 기존 시스템 한계

경희대GPT (RAG 기반) 시도 → 실용화 실패

- 응답 지연 (LLM 의존)
- 실시간 정보 반영 불가
- 데이터 소스 통합 어려움

💡 제안 솔루션

Agent KHU는 MCP(Model Context Protocol) 기반
마이크로서비스 아키텍처와
Hybrid LLM/SLM 라우팅을 결합하여

분산된 학사정보를 **단일 자연어 인터페이스**로
통합 제공하는 AI 캠퍼스 어시스턴트

시스템 아키텍처

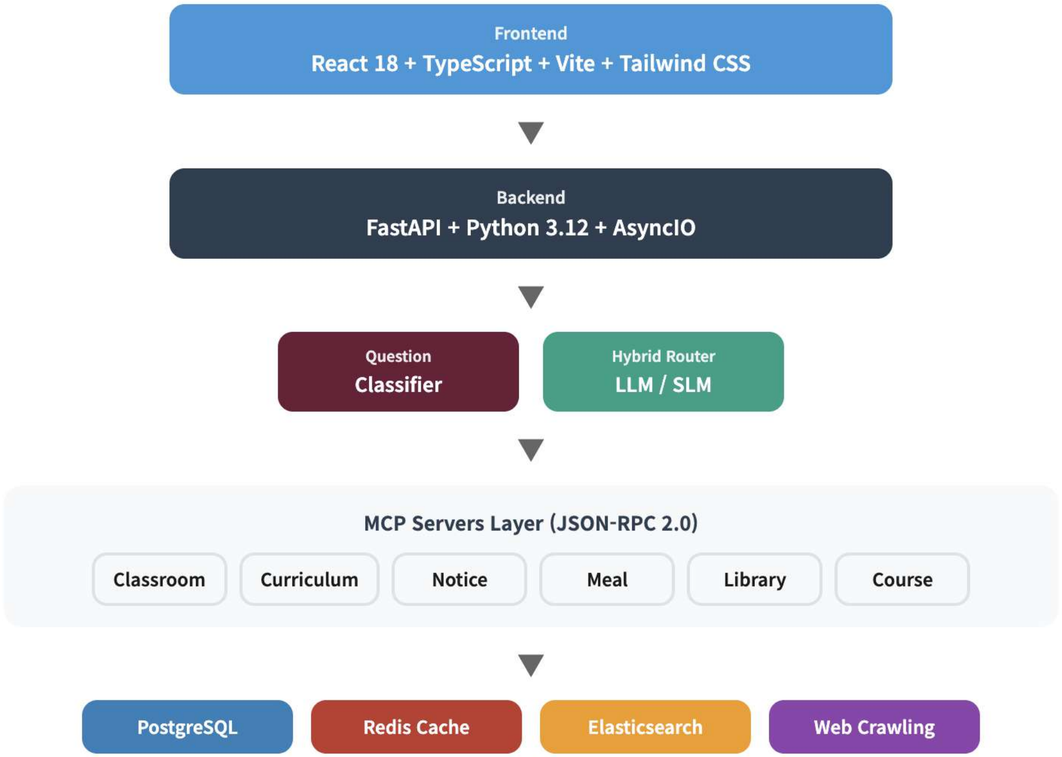
Frontend
React 18 + TypeScript + Vite + Tailwind CSS
Backend
FastAPI + Python 3.12 + AsyncIO
Question
Classifier
Hybrid Router
LLM / SLM
MCP Servers Layer (JSON-RPC 2.0)
Classroom
Curriculum
Notice
Meal
Library
Course
PostgreSQL
Redis Cache
Elasticsearch
Web Crawling

Hybrid LLM/SLM 라우팅

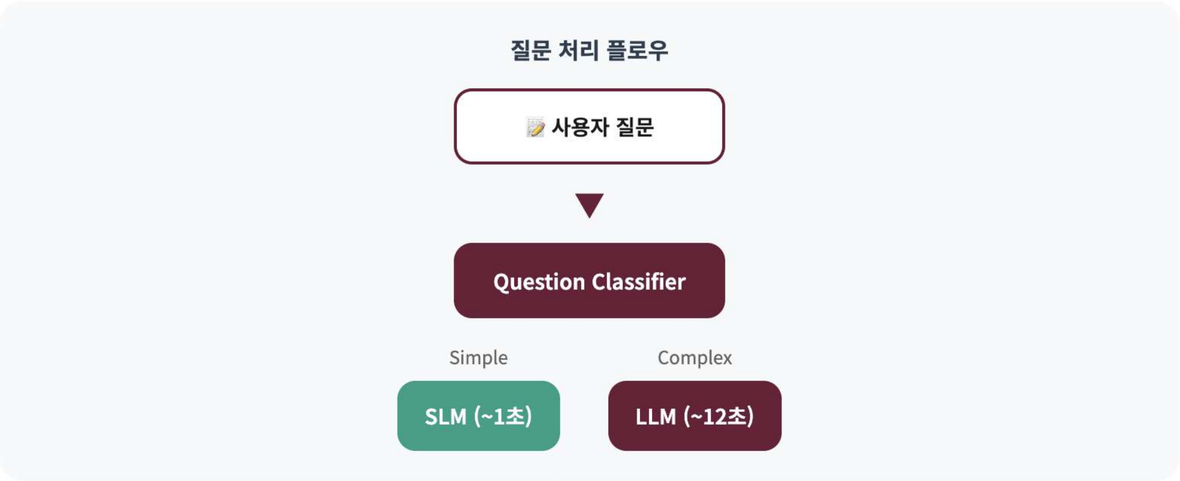


```
class QuestionClassifier: SIMPLE_PATTERNS = [ r"몇\s*학점", r"언제", r"어디", r"위치", r"메뉴", r"식단" ]
COMPLEX_PATTERNS = [ r"추천", r"비교", r"분석", r"졸업\s*요건", r"계획" ] def classify(self, question): # 1.
Complex 패턴 우선 체크 for p in self.COMPLEX_PATTERNS: if re.search(p, question): return "complex" # 2.
Simple 패턴 체크 for p in self.SIMPLE_PATTERNS: if re.search(p, question): return "simple" # 3. 휴리스틱 if
len(question) > 50: return "complex" return "simple"
```

Simple 패턴

"몇 학점", "언제", "어디"
"위치", "메뉴", "강의실"

Complex 패턴

"추천", "비교", "분석"
"졸업요건", "계획"

✨ Simple 질문 응답시간: 7초 → 1초 (85% 단축) | SLM 신뢰도 임계값: 0.7 | Fallback 비율: ~15-20%

MCP (Model Context Protocol)

🔌 MCP란?

AI 모델과 외부 Tool을 연결하는 **표준 프로토콜**
Anthropic에서 제안, JSON-RPC 2.0 기반 stdio 통신

📦 구현된 MCP 서버

Classroom 강의실 위치 (DB)	**Curriculum** 교과과정 (JSON)
Notice 공지사항 (크롤링)	**Meal** 학식 (Playwright)
Library 도서관 좌석	**Course** 수강신청

```
// JSON-RPC 2.0 요청 { "jsonrpc": "2.0", "id": 1, "method": "tools/call", "params": { "name":
"search_classroom", "arguments": {"query": "전137"} } }
```

✅ 핵심 설계 결정

매 호출마다 세션 생성/종료

- Context 불일치 문제 완전 해결
- "handler is closed" 에러 방지
- 에러율: 15% → 2% **(87% 감소)**

캐싱 전략 & Observability

🚀 Redis 캐싱 (Tool별 TTL)

데이터 유형	TTL	대상	응답속도
정적 데이터	24시간	강의실, 교과과정	~10ms
주기적 업데이트	2시간	공지사항	~10ms
자주 변경	1시간	도서관, 학식	~10ms
실시간	1분	좌석 현황	~10ms

📈 캐싱 성과

캐시 히트 시 응답속도 **80% 개선**
히트율: 60-70% (반복 질문 많은 사용자)

📊 Elasticsearch 로깅

```
{ "timestamp": "2025-12-19T...", "question": "자료구조 몇 학점?", "user_id": "user_123", "question_type": "simple", "routing_decision": "slm", "mcp_tools_used": ["curriculum"], "latency_ms": 1023, "success": true }
```

🎯 활용 방안

- **SLM 학습 데이터**: 질문-응답 쌍 축적
- **성능 모니터링**: P50/P95/P99 추적
- **A/B 테스팅**: 라우팅 전략 비교
- **오류 분석**: 실패 패턴 식별

MCP 최적화 사례

🏫

Classroom MCP

❌ Before: 실시간 크롤링
→ 수 초 지연, 불안정

✅ After: 사전 수집 + DB 조회
→ **0.5초 미만**

매일 자정 데이터 갱신

📚

Curriculum MCP

❌ Problem: HTML rowspan 파싱
→ 학년-과목 매핑 오류

✅ Solution: rowspan 알고리즘 구현
→ 동적 인덱스 조정

정확도 100% 달성

🍽️

Meal MCP

❌ Problem: Playwright 크래시
→ Docker 의존성 문제

✅ Solution: Graceful Degradation
→ 실패 시 링크 제공

일 단위 캐싱 적용

💡 **핵심 교훈: 실시간 크롤링보다 사전 수집 + 캐싱이 안정성과 속도 모두 우수**

성능 벤치마크 결과

67%

응답시간 단축

16.6초 → 5.5초

87%

MCP 에러율 감소

15% → 2%

80%

캐시 응답 개선

Redis TTL 최적화

48%

LLM 호출 절감

Hybrid 라우팅 효과

📊 **벤치마크 기준: 2025년 12월 17일 측정 | 질문 유형별 100회 이상 반복 측정 평균값**

기술적 챌린지 & 해결

🔄 MCP Context 오류

문제: 세션 재사용 시 "handler is closed" 에러

원인: AsyncIO Context 불일치

✅ 매 호출 세션 생성/종료

에러율 15% → 2%

⏱️ 응답 지연

문제: 모든 질문에 LLM 호출 → 평균 16.6초

원인: 단순 질문도 Claude API 대기

✅ Hybrid LLM/SLM 라우팅

Simple 질문 85% 단축

💾 크롤링 불안정

문제: 실시간 크롤링 → 타임아웃, 실패

클릭하면 이전 페이지로 가고 누르고 있으면 방문 기록이 나타납니다.

웹 의존성

✅ 사전 수집 + DB/캐시

응답속도 0.5초 미만

💡 핵심 교훈

실제 프로덕션 환경에서는 이론적 설계와 다른 문제가 발생하며,
측정과 분석을 통한 점진적 개선이 필수적입니다.

클릭하면 이전 페이지로 가고 누르고 있으면 방문 기록이 나타납니다.

활용 사례 & 데모

신입생 강의실 찾기

"전137 어디 있어?"

→ Classroom MCP 호출 → "전자정보대학 137호" 위치 + 네이버 지도 링크

0.5초

졸업요건 확인

"컴공 19학번 졸업요건 알려줘"

→ Curriculum MCP 호출 → 2019학번 전공별 이수학점 + 출처 링크

0.7초

복합 질의

"오늘 학식 뭐야? 그리고 도서관 빈 자리 있어?"

→ Meal MCP + Library MCP 호출 → 식단 + 열람실 좌석 현황 통합 응답

1.2초

💬 Claude가 질문을 분석하여 **자율적으로 필요한 MCP 서버를 선택** → Tool Use 패턴

향후 계획

1

단기 (1주)

- MCP 병렬 호출 (asyncio.gather)
- SLM 신뢰도 임계값 A/B 테스팅
- Notice MCP 크롤링 최적화

2

중기 (1개월)

- SLM Fine-tuning (Observability 데이터 활용)
- 캐시 워밍업 자동화
- Grafana 메트릭 대시보드

3

장기 (3개월)

- Multi-Modal Agent (이미지, 음성)
- 개인화 프롬프트 생성
- 소융대 → 전체 캠퍼스 확장

🎯 기대 효과

SLM Fine-tuning

Claude API 호출 90% 절감 예상

MCP 병렬 호출

복합 질의 응답시간 40% 추가 단축

전 캠퍼스 확장

경희대 전체 학생 대상 서비스

클릭하면 이전 페이지로 가고 누르고 있으면 방문 기록이 나타납니다.

결론 & 핵심 성과

📌 프로젝트 성과

평균 응답시간	16.6s → 5.5s	-67%
MCP 에러율	15% → 2%	-87%
LLM 호출 절감	82% → 38%	-48%
캐시 응답 개선	최대	80%↑

🔧 기술적 의의

- **Hybrid LLM/SLM**: 복잡도 기반 동적 라우팅
- **MCP 표준 준수**: 공식 SDK 활용 안정적 통합
- **계층적 캐싱**: Tool별 TTL 최적화
- **Observability**: 데이터 기반 지속 개선

Agent KHU

MCP 기반 마이크로서비스 아키텍처와
Hybrid LLM/SLM 라우팅을 결합하여

분산된 학사정보를
단일 자연어 인터페이스로 통합

다른 대학 및 조직에서도
쉽게 활용 가능한 **확장 가능 플랫폼**

감사합니다

Agent KHU

MCP 기반 AI 캠퍼스 정보 플랫폼

정윤서

경희대학교 컴퓨터공학부

github.com/jys0615/agent-khu